

深層学習による画像認識を用いた コンクリート構造物の変状検出に関する研究

青島 亘佐¹・河村 伸哉²・中野 聡³・中村 秀明⁴

¹正会員 株式会社福山コンサルタント (〒112-0004 東京都文京区後楽2-3-21)

E-mail: aoshi@fukuyamaconsul.co.jp

²非会員 山口大学大学院 創成科学研究科 電気電子情報系専攻 (〒755-8611 宇部市常盤台2-16-1)

E-mail: i023vg@yamaguchi-u.ac.jp

³正会員 株式会社福山コンサルタント (〒112-0004 東京都文京区後楽2-3-21)

E-mail: nakano@fukuyamaconsul.co.jp

⁴正会員 山口大学大学院教授 創成科学研究科 電気電子情報系専攻 (〒755-8611 宇部市常盤台2-16-1)

E-mail: nakahide@yamaguchi-u.ac.jp

社会インフラの維持管理において、目視点検の省力化および効率化を図ることが近年の喫緊の課題の一つとなっている。そこで、本研究では、この課題を解決するため、デジタルカメラにより取得した画像に対して深層学習による画像認識を適用し、変状を自動的に検出して損傷程度の区分(ランク)に関するクラス分類を行う手法について検討を行った。また、実構造物での変状画像を用いた検証により、深層学習による画像認識が、目視点検の省力化および効率化に対して有効な手法であることを確認した。

Key Words : concrete structure, bridge inspection, deep learning, image recognition, object detection, convolutional neural network (CNN), data augmentation, transfer learning

1. はじめに

高度経済成長期に建設された膨大な社会インフラが、近い将来一斉に更新時期を迎えることが予見されている。そこで、主要な構造物に対しては、定期点検の実施および長寿命化修繕計画の策定が推進されてきた。しかしながら、近年のデフレが進行する社会情勢や財政事情を反映して、社会インフラのメンテナンスに対する投資や施策等が十分とはいえない状況が長く続いている。このような状況下で、2012年12月に笹子トンネルにおいて老朽化した天井板が崩落し、9名の方が亡くなるという痛ましい事故が発生し、社会インフラの本格的なメンテナンス体制の見直しを行う契機となった。全国の道路構造物のうち、約70万の橋梁や約1万のトンネル等については、近接目視による5年に1回の定期点検が法律で定められ、平成26年7月1日より施行された¹⁾。この法律の改正により、主要な道路構造物に対する点検は、これまで以上に膨大な予算およびマンパワーが必要となった。

一方、熟練技術者の退職や生産年齢人口の減少により、今後の専門技術者の不足が懸念されている。さらに、現

在政府は「働き方改革」で労働時間の短縮を目指しており、社会インフラのメンテナンス分野においても労働生産性の向上が喫緊の課題となっている。

このような社会事情から、構造物の点検を合理的かつ経済的に推進していくための方策としてIoTやAI等の情報処理技術の活用が考えられる。これまでに、コンクリート構造物のひび割れの抽出等において画像処理技術や最適化手法、機械学習等を応用する研究が盛んに行われている。

その先駆けとなったものは、1998年に販売されたコンクリート構造物診断支援ソフトで、画像処理技術を活用し、オペレーターが判断しながらコンクリート表面のひび割れや剥落を半自動で抽出するソフトであった²⁾。その後も、外業における変状状況の記録および内業におけるそれらの整理の省力化を目的とした技術開発が進められている。特に、コンクリートの代表的な変状であるひび割れは、点検時の記録に労力を要することから自動検出に関する研究が数多く行われている。

山口・橋本³⁾⁴⁾は、ひび割れの局所的な直線性と方向性に着目したGray-scale Hough 変換や形状情報と輝度情報を

付加したパーコレーション処理による高精度化検出手法を提案している。藤田ら⁹⁾は、多重スケール線強調処理および確率的弛緩法を用いて、幅別の分類が可能で、かつパラメータの設定を不要としたひび割れの検出手法を提案している。全・橋本ら⁹⁾は、統計的な閾値の導出による二値化処理、連結要素における幾何学的特徴に着目したひび割れ候補の絞り込みによるひび割れの検出手法を提案している。そして、ハフ変換により型枠跡およびPコン跡を同定して誤検出結果から除去することで自動検出の精度向上も図っている。画像の輝度以外の要素に着目した手法では、例えば小山・丸屋ら¹⁰⁾¹²⁾が提案した、デジタル画像にガボールフィルタに基づいたウェーブレット変換を適用してウェーブレット係数によりひび割れ判定を行う研究があり、実構造物での検証も行っている。遺伝的プログラミングあるいは遺伝的アルゴリズムを利用した手法では、例えば西川ら¹³⁾は、遺伝的プログラミングにより木構造状フィルタ生成システムを構築し、これにより生成されたロバストな複合画像フィルタによるひび割れ検出手法を提案している。また、河村ら¹⁴⁾¹⁶⁾は、対話型遺伝的アルゴリズムを用いた視覚的な画像処理パラメータ調整手法を提案している。近年では、深層学習を利用した研究もあり、例えば野村ら¹⁷⁾は、深層学習に基づく一般物体検出手法によるひび割れ検出を行なっている。機械学習あるいは深層学習と他の手法を組み合わせた研究では、例えば全・井後による画像解析とRandom Forestによる機械学習を基にした大局的形状判定手法を組み合わせたひび割れ検出手法¹⁸⁾、それを発展させた深層学習とRandom Forestによるひび割れ検出手法¹⁹⁾がある。さらに、中村・河村ら²⁰⁾による深層学習と対話型遺伝的アルゴリズムによる半自動的抽出手法を組み合わせたひび割れ検出手法等がある。

これらの様々な研究によりコンクリート構造物の点検効率化に有益な知見が得られている。しかしながら、いずれもコンクリートのひび割れを対象とした研究で、構造物の点検要領で規定されている「剥離・鉄筋露出」や「漏水・遊離石灰」等の他の変状までは対象としていない。ひび割れ以外の変状を扱った研究として、トンネルの事例では、例えば石森・塩崎・佐田ら²¹⁾²⁴⁾は、照明による陰影を利用して覆工コンクリート表面のひび割れとともに段差を検出する手法を提案している。また、鶴飼ら²⁵⁾²⁷⁾は、変状に応じた画像処理アルゴリズムを用いることにより、ひび割れのみならず閉合ひび割れや漏水、エフロッセンスを検出する手法を提案している。この手法は、ラインセンサカメラを用いたトンネル変状検査システムとして、多くの鉄道路線で適用されている。トンネル以外の事例としては、横山・松本²⁸⁾³⁰⁾によるコンクリート全般を対象とした深層学習による画像認識を用いた手法がある。この手法では、ひび割れとともにエフ

ロッセンス、チョーク文字を検出することが可能である。また、鶴飼・長峯³¹⁾は、橋梁を対象として、閾値処理を行って抽出した領域と元画像の論理積を用いて、対象領域の絞り込みおよびエッジ抽出等を行い、はつり跡や修復跡を検出する手法を提案している。

構造物の点検要領は、インフラの管理者や施設により対象とする変状およびその状況の評価は多様である。変状検出に関する研究は進んでいるものの、特定の点検要領に準拠した変状の検出までには至っていないため、これらの研究が道路構造物の点検に広く用いられていないものと考えられる。

そこで、本研究では、一般的な点検作業で重要となる変状の検出とその損傷程度のランク付けに関する作業の効率化を目的に、深層学習による画像認識の適用性と精度向上について検討する。具体的には、膨大なストック量である一般道路の橋梁に広く適用されている国土交通省の橋梁定期点検要領³²⁾に準拠し、ひび割れや剥離・鉄筋露出、漏水・遊離石灰の分類も含めた変状の検出と損傷程度のランク付けを行った。

2. 点検要領の損傷に対する画像認識の適用

(1) 道路橋の定期点検

一般道路の道路橋に対する定期点検では、国土交通省の橋梁定期点検要領で規定された26損傷(表-1参照)が、多くの道路管理者により採用されている。

現地での外業では、発見した損傷に対して、部位や部材の最小評価単位ごと、損傷の種類ごとに主要な寸法の計測や写真撮影、状況のスケッチ等を行って損傷状況を把握し、損傷に関する客観的な事実により設定された区分に基づき分類を行う。また、内業では、スケッチを基にCAD等により損傷図の作成を行い、変状写真や所見等とともに橋梁単位で点検調書の取りまとめを行い、健全性の診断や、維持・補修等の計画の検討に利用する基礎資料として蓄積される。本研究では、これらの工程のうち、スケッチによる記録や程度の評価、損傷図作成工程の効率化に寄与する技術について検証を行う。

(2) 本研究における対象損傷

本研究では、橋梁定期点検要領で規定された26損傷のうち、コンクリートの変状に着目して、深層学習の学習に必要な一定量のサンプルが確保できる橋梁点検時の撮影画像を用いて、画像認識の検討を行う。

なお、学習に用いる画像が少ない「抜け落ち」や、損傷の有無について画像からの判断が困難な「うき」、床版特有の条件を加味した画像が少なく、「ひびわれ」と傾向が類似する「床版ひびわれ」は対象から除外した。

表-1 橋梁定期点検要領における着目損傷³²⁾

材料	番号	損傷の種類	材料	番号	損傷の種類
鋼	[1]	腐食	その他	[13]	遊間の異常
	[2]	亀裂		[14]	路面の凹凸
	[3]	ゆるみ・脱落		[15]	舗装の異常
	[4]	破断		[16]	支承部の機能障害
	[5]	防食機能の劣化		[17]	その他
コンクリート	[6]	ひびわれ	共通	[10]	補修・補強材の損傷
	[7]	剥離・鉄筋露出		[18]	定着部の異常
	[8]	漏水・遊離石灰		[19]	変色・劣化
	[9]	抜け落ち		[20]	漏水・滞水
	[11]	床板ひびわれ		[21]	異常な音・振動
	[12]	うき		[22]	異常なたわみ
				[23]	変形・欠損
				[24]	土砂詰まり
				[25]	沈下・移動・傾斜
				[26]	洗掘

表-2 対象損傷の損傷程度の区分と分類クラスの関係

損傷種類	区分	一般的状況 ³²⁾	分類クラス
ひびわれ	a	損傷なし	—
	b	最大ひびわれ幅：小 最小ひびわれ間隔：小	クラス1
	c	最大ひびわれ幅：小 最小ひびわれ間隔：大	
	d	最大ひびわれ幅：中 最小ひびわれ間隔：小	
	e	最大ひびわれ幅：大 最小ひびわれ間隔：大	
剥離・鉄筋露出	a	損傷なし	—
	b	—	—
	c	剥離のみが生じている。	クラス2
	d	鉄筋が露出しており、鉄筋の腐食は軽微である。	クラス3
	e	鉄筋が露出しており、鉄筋が著しく腐食又は破断している。	クラス4
※漏水・遊離石灰	a	損傷なし	—
	b	—	—
	c	ひびわれから漏水が生じている。錆汁や遊離石灰はほとんど見られない。	クラス5
	d	ひびわれから遊離石灰が生じている。錆汁はほとんど見られない。	クラス6
	e	ひびわれから著しい漏水や遊離石灰（例えば、つらら状）が生じている。漏水に著しい泥や錆汁の混入が認められる。	クラス7
			クラス8

※）打継目や目地部から生じる漏水・遊離石灰についても、ひびわれと同様の扱いとする。

また、対象損傷のうち、「ひびわれ」については、ひび割れの幅や間隔の定量的情報がないと画像のみでは人間の目でも損傷程度の識別は困難なため、ひび割れの有無のみの識別を行うこととした。以上の損傷を対象として、本研究では、変状写真に対して、深層学習による画像認識を用いて、変状位置を特定するとともに、損傷の種類とその程度の判別を行う。具体的な判別内容は、表-2に示す「ひびわれ」、「剥離・鉄筋露出」、「漏水・遊離石灰」の損傷程度の区分（ランク）内容に応じた8つのクラスである。各クラスの変状写真の事例を図-1に示す。

(3) 橋梁点検時の撮影画像

一般に、深層学習の学習においては、ネットワークの種類や構成等以上に、学習サンプルが重要だと言われている³³⁾。本研究で用いる橋梁点検時の撮影画像は、最小限の量は確保できたものの、深層学習における学習画像としての使用を目的として撮影された画像ではない。また、日射や影の影響を受けにくく撮影距離が概ね一定であるトンネルのような撮影条件に対して、橋梁は多様な撮影条件が前提となる。これらのことを鑑みると、橋梁点検時の撮影画像は、深層学習に用いる学習データとして、以下の点から質や特徴量の面で適しているとはいえない。

- ・点検調査書のデータ容量を縮減するために、画像については解像度を低くしている
- ・撮影距離が多様（近接して撮影した画像、変状箇所周辺まで含めて撮影した画像等）
- ・撮影時の角度が多様（変状に正対して撮影した画像、点検条件より斜方向から撮影した画像等）
- ・撮影時の照度が多様（日向、日陰、夜間等）

しかし、現在、国土交通省では、インフラ点検・施工管理等へのAIの活用促進を目的として、構造物点検時の画像データについて、十分に精査した上で教師データとして公開することが検討されている³⁴⁾。そのため、構



図-1 各クラスの変状写真の事例

造物点検時の画像データについて、深層学習への適性に関する検証を行うことは、今後のAIの活用促進を見据えると意義があると考えられる。

3. 深層学習による画像認識

(1) 深層学習による物体検出

深層学習に関する技術は、近年著しい進展を遂げており、現在では特定のタスクにおける識別能力は人間と比肩するレベルに達し、適用されるタスク領域が広がり、飛躍的な精度の向上がみられる。特に画像データへの適用は、深層学習の分野の中で最も研究が盛んな分野の一つで、幅広い研究が行われている。画像認識のタスクは、一般的に「物体認識」、「物体検出」、「セグメンテーション」の3段階に大きく分類されており、この順にタスクの難易度は高くなる。本研究で検討を行う変状の検出は「物体検出」のタスクに該当する。

深層学習による物体検出の近年の潮流は、R-CNN (Regions with CNN features)³⁵⁾に依るところが大きい。R-CNNは、PASCAL VOCの画像データセットについての2012年時点のmAP（平均適合率APの平均）の最高値を30%以上向上させたことで脚光を浴びた物体検出手法で



図-2 物体認識および物体検出のイメージ図

ある。手順としては、Selective Search³⁶⁾等の物体候補領域の探索手法により得られた領域の画像を、CNN (convolutional neural network)³⁷⁾に入力し、適切なクラスへの分類を行う物体認識の工程を経て、検出が行われる。R-CNN以後も文献^{38) 44)}等にあるように、より高速で高精度な物体検出手法が提案されているが、物体認識の工程を経るという点ではR-CNNと共通しており、いずれの手法においても検出の精度向上のためには物体認識の精度向上の検証が不可欠である。

物体認識および物体検出のイメージを図-2に示す。

(2) 検証の流れ

本研究の最終目的は、物体検出(変状箇所の検出)であるが、物体検出の実現性確認のために、その前段階として難易度が一段階低いタスクである物体認識(変状のクラス分類)についての検証を始めに行う。その後、物体検出について検証を行う。検証の流れを図-3に示す。

a) 物体認識(変状のクラス分類)についての検証

CNNに代表される深いニューラルネットワークを用いたモデルは、深層学習の中でも過学習に陥りやすいとされている。過学習とは、学習データに過剰に適合したパラメータが出来上がってしまい、学習データに対しては非常に高い分類精度となるが、学習データと異なる未知のデータに対しては精度が低く適合できていない(汎化できていない)状態に陥る現象である。このような過学習の抑制および分類精度の向上を図った上で、橋梁点検時の撮影画像に対して、変状のクラス分類を行う。

本研究のクラス分類で用いるデータセットは、道路橋点検時に撮影された画像に対して、道路橋点検士有資格者により正解クラスのラベル付を行なって作成した、画像とラベルが対になったデータである。なお、物体認識では、画像がどのクラスに該当するかの分類を行うため、

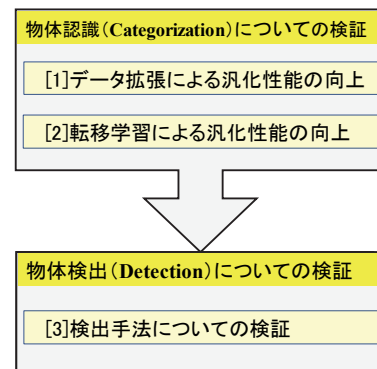


図-3 深層学習による画像認識の検証の流れ




図-4 クラス分類における交差検証の概要


学習に用いた画像は、単一のクラスの変状のみが存在する画像を選定している。ただし、データセットは、各クラスにつき約150画像でデータ量としては十分ではないため、データの偏り等による過学習が懸念される。

データ量の不足を補い、過学習の抑制および分類精度向上を図る方策として、基本的な前処理である「コントラスト調整」、擬似的なデータを作成してデータ量を増加させる「データ拡張(Data Augmentation)」、他の関連した問題のデータや学習結果を再利用する「転移学習(Transfer Learning)」を行い、効果を検証する。

また、限られたデータの中で検証の信頼性を向上させるため、本研究では、図-4に示すK-分割交差検証により評価を行った。K-分割交差検証では、データセットをK個に分割し、そのうちの(K-1)/Kをモデル自体の調整(学習)に用いる学習(training)データとし、残りの1/Kを学習の結果の評価に用いる検証(validation)データとする。本研究では、K=5としてデータセットを5分割し、全データの80%を学習データ、20%を検証データとし、5回の検証結果を平均して分類結果とする。また、テストに用いるデータとして、データセットとは別に、学習にも検証にも使用していないテスト(test)データも用意した。

b) 物体検出(変状箇所の検出)についての検証

物体検出では、物体検出用のデータセットを作成した上で複数の深層学習による物体検出手法を用いて画像から変状箇所の検出を行い、検出結果の妥当性を確認する。そして、それぞれの手法について、コンクリートの変状箇所の検出に対する適性を検証する。


図-5 CNNの構成イメージ例（文献⁴⁰図2を改変）

4. 変状のクラス分類

(1) CNNによるクラス分類

CNNは、2012年のILSVRC（ImageNet Large-scale Visual Recognition Challenge）の画像のクラス分類の部門で、トロント大学のHinton教授らのグループが、CNNを用いた手法で2位以下のチームに大差を付けて圧勝したことで注目を集めた⁴⁵。その後も画像認識の分野で、教師あり学習における画像のクラス分類を中心に高い性能を発揮している。CNNは、順伝播型ニューラルネットワークの一種で、中間層の畳み込み層（convolutional layer）とプーリング層（pooling layer）を複数つなぎ合わせた深い階層を持ち、表現学習を行って最適となる特徴を抽出し、最終的にクラス分類を行うネットワークである。人間の手を介さずに、ネットワークの学習を通して、特定概念を特徴づける特徴量を自動抽出できる。この点が、深層学習が画像認識の分野で既存手法を著しく上回る精度を実現した要因である。

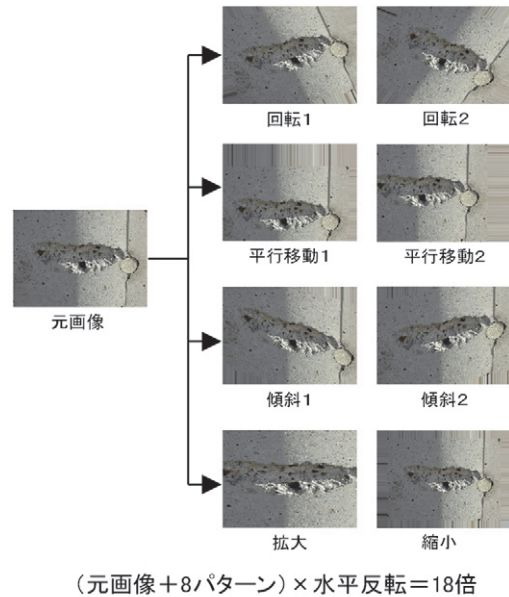
CNNの一般的なネットワーク構成を図-5に示す。

(2) 汎化性能向上の方策

画像認識において、学習された認識モデルの性能を向上させるためには、認識モデルの設計や学習方法も重要であるが、性能に一番影響を及ぼすのは学習画像である。そのため、まず学習画像の質と量を改善する必要がある。以下に、汎化性能を向上させる各種方策について述べる。

a) データ拡張（Data Augmentation）

深層学習の実施には、一般的に大量のデータが必要とされているが、本研究では必要十分なデータ量は確保できていない。データ拡張は、今回のような限られたサンプル数で深層学習を行う場合に、保有するデータを基に擬似的なデータを作成してデータ量の拡張を図り、データ不足を補って認識をロバストにする手法である。今回のクラス分類では、回転・平行移動・傾斜・拡大・縮小



(元画像+8パターン)×水平反転=18倍

図-6 データ拡張の実施例




図-7 mixupの実施例

小・水平反転を組み合わせ、保有データの18倍の拡張を行った。データ拡張の実施例を図-6に示す。

また、新たなデータ拡張手法であるmixup⁴⁷⁾についても検討を行なった。mixupとは、異なるクラス間の組み合わせも含むランダムに選んだ2つの学習データをマー

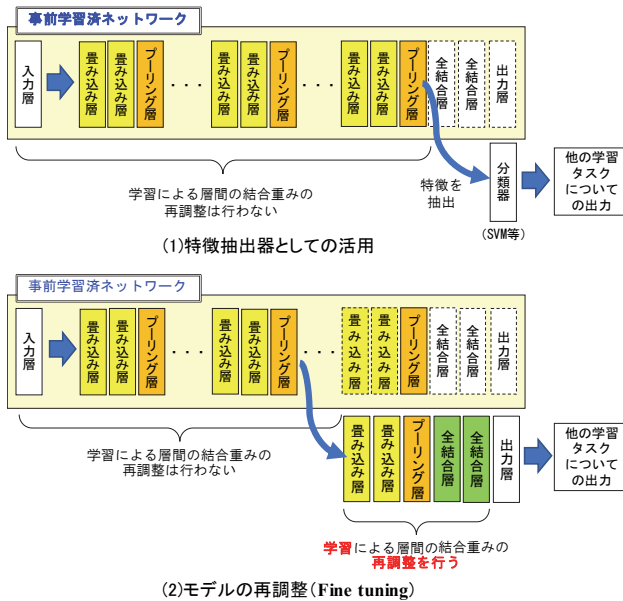


図-8 転移学習の概要

ジシ、新たな学習データを生成する手法である。具体的には、画像データ x とラベル y のペア (x_1, y_1) , (x_2, y_2) から、式(1),(2)により新たな画像 x とラベル y を作成する。なお、画像に対する正解ラベルは、one-hot表現（正解クラスが1でその他のクラスは0となるビット列）になっているものとする。mixupの実施例を図-7に示す。mixupでは、それぞれのクラスの補間画像を生成することができることから、劣化損傷のように時系列的に徐々に変化する物に対しては有効となる可能性がある。

$$x = \lambda \cdot x_1 + (1 - \lambda) \cdot x_2 \quad (1)$$

$$y = \lambda \cdot y_1 + (1 - \lambda) \cdot y_2 \quad (2)$$

b) 転移学習 (Transfer Learning)

転移学習とは、既に学習済みのモデルの知識や特徴を再利用し、学習時間の削減や学習データ不足等を補う手法である。CNNにおける転移学習の手法は、主に図-8に示す2つがある。一つは、学習済みモデルの出力層以外の部分を、層間の結合重みは変更せずに特徴抽出器として使用し、分類等のためにSVM（サポートベクターマシン）等の機械学習モデルへの入力とする手法である。もう一つは、Fine-tuningと呼ばれる手法で、初期値は学習済みモデルの層間の結合重みをそのまま使い、学習し直して当該タスクに適した重みに再調整する手法である。

本研究では120万枚・1000クラスから構成されるImageNetと呼ばれる大規模な画像データセットを学習したモデルをもとにFine-tuningを行った。CNNでは、入力層に近い層ではエッジ等の低次の汎用的な特徴が抽出されるのに対し、出力層に近い層では当該タスクの学習データに特化した特徴が抽出される傾向にあるとされてい

表-3 クラス分類の検討ケース

No.	処理条件	検討条件		
		Fine-tuning	データ拡張 (従来)	データ拡張 (mixup)
ケース 1	未処理	—	—	—
ケース 2	データ拡張	—	●	—
ケース 3	Fine-tuning	●	—	—
ケース 4	Fine-tuning+データ拡張	●	●	—
ケース 5	Fine-tuning+mixup	●	—	●

		予測クラス	
		Positive (予測結果が正)	Negative (予測結果が負)
正解クラス	Positive (正解クラスが正)	真陽性 TP (True Positive)	偽陰性 FN (False Negative)
	Negative (正解クラスが負)	偽陽性 FP (False Positive)	真陰性 TN (True Negative)

図-9 混同行列 (Confusion Matrix)

る⁴⁹⁾。そのため、出力層に近い層において学習を行い、モデルの再調整を行なった。

(3) クラス分類結果

a) 分類結果

入力画像について未処理の状態、データ拡張あるいはmixupを行なった状態と、Fine-tuningの実施を組み合わせることで表-3に示す計5ケースの学習を行い、汎化性能の向上について検証を行った。CNNによる分類では、図-5中の出力層において、8クラスそれぞれの判定確率が出力として得られ、その確率が最大となるクラスを予測クラスとしている。各ケースの分類結果は、図-9に示す混同行列の形式で整理を行った。混同行列とはクラスの分類結果をまとめたもので、正しく分類できた割合（再現率 [真陽性率] = $TP / (TP + FN)$ ）、誤って分類した割合（偽陰性率 = $FN / (TP + FN)$ ）を知ることができる。表-4～9に各ケースの分類結果（混同行列）を、図-10～17にそれぞれの変状のケース別再現率を示す。図-10～17によると、Fine-tuningの実施により、再現率の大幅な向上が見られた。事前学習に用いられているImageNetのデータセットは、一般的な物体のデータセットでコンクリートの変状等の特殊なクラスは含まれていない。しかし、入力に近い層で行われる汎用的な特徴の抽出は、全く異なるクラスであるコンクリートの変状に対する学習においても十分な効果が得られていると思われる。また、一般に、CNNの学習は初期値依存性が強く、特に学習データが少ない場合は、過学習の抑制の観点からも適切な初期値を与えることが重要とされている⁴⁹⁾。この点からも、再現率の大幅な向上に寄与したものと考えられる。

データ拡張については、Fine-tuningとの組み合わせでは表-9および図-12に見られるように漏水・遊離石灰dで

表-4 ケース1(未処理)の分類結果

		分類結果 (%)							
		ひび割れ	漏水・遊離石灰				剥離・鉄筋露出		
			c	d	e-1 つらら	e-2 錆汁	c	d	e
正解クラス	ひび割れ		61.1	5.5	14.4	0.0	3.3	6.7	0.0
	漏水・遊離石灰	c	14.5	14.4	11.1	3.3	14.5	15.5	22.2
		d	42.2	4.5	22.2	0.0	2.2	12.2	16.7
	剥離・鉄筋露出	e-1	0.0	5.6	9.3	9.3	25.9	16.7	24.1
		e-2	8.9	16.7	3.3	0.0	27.8	5.6	21.1
	剥離・鉄筋露出	c	31.1	5.6	13.3	1.1	3.3	21.1	20.0
		d	11.1	2.2	8.9	1.1	5.5	10.0	54.5
		e	0.0	5.6	0.0	0.0	5.5	7.8	81.1

表-7 ケース4(Fine-tuning+データ拡張)の分類結果

		分類結果 (%)							
		ひび割れ	漏水・遊離石灰				剥離・鉄筋露出		
			c	d	e-1 つらら	e-2 錆汁	c	d	e
正解クラス	ひび割れ		96.7	0.0	0.0	2.0	0.0	0.7	0.7
	漏水・遊離石灰	c	5.3	78.0	4.7	0.0	8.0	0.0	2.7
		d	2.0	2.6	86.0	5.3	0.0	3.3	0.0
	剥離・鉄筋露出	e-1	0.0	3.4	11.1	83.3	0.0	1.1	1.1
		e-2	0.0	0.0	0.7	4.0	91.3	0.0	4.0
	剥離・鉄筋露出	c	0.0	1.3	1.3	0.0	0.0	97.4	0.0
		d	0.0	3.3	0.0	0.0	0.0	2.6	88.7
		e	0.0	0.0	0.0	0.0	1.3	2.0	96.7

表-5 ケース2(データ拡張)の分類結果

		分類結果 (%)							
		ひび割れ	漏水・遊離石灰				剥離・鉄筋露出		
			c	d	e-1 つらら	e-2 錆汁	c	d	e
正解クラス	ひび割れ		66.7	4.4	16.7	1.1	2.2	3.3	5.5
	漏水・遊離石灰	c	7.8	10.0	11.1	7.8	32.2	7.8	21.1
		d	20.0	3.3	35.6	10.0	2.2	18.9	6.6
	剥離・鉄筋露出	e-1	3.7	9.3	14.8	16.7	14.8	16.7	11.1
		e-2	0.0	15.6	0.0	1.1	56.7	3.3	11.1
	剥離・鉄筋露出	c	22.2	0.0	11.1	12.2	5.5	32.2	15.5
		d	1.1	4.4	7.8	5.6	14.4	8.9	50.0
		e	0.0	1.1	0.0	3.3	27.8	0.0	4.4

表-8 ケース5(Fine-tuning+mixup)の分類結果

		分類結果 (%)							
		ひび割れ	漏水・遊離石灰				剥離・鉄筋露出		
			c	d	e-1 つらら	e-2 錆汁	c	d	e
正解クラス	ひび割れ		92.7	2.0	1.3	0.0	0.0	0.7	2.6
	漏水・遊離石灰	c	8.0	64.7	7.3	0.7	6.7	1.3	9.3
		d	0.7	4.7	75.3	6.0	0.7	9.3	2.0
	剥離・鉄筋露出	e-1	2.2	2.2	11.1	66.7	3.4	1.1	7.8
		e-2	0.0	2.6	2.6	2.0	86.7	0.0	6.0
	剥離・鉄筋露出	c	0.0	2.6	2.7	0.0	0.7	93.4	0.0
		d	1.3	2.7	2.0	0.0	2.0	3.3	85.3
		e	0.0	0.0	0.0	0.0	0.7	4.0	94.7

表-6 ケース3(Fine-tuning)の分類結果

		分類結果 (%)							
		ひび割れ	漏水・遊離石灰				剥離・鉄筋露出		
			c	d	e-1 つらら	e-2 錆汁	c	d	e
正解クラス	ひび割れ		91.3	2.7	0.0	0.0	0.7	0.0	5.3
	漏水・遊離石灰	c	8.0	58.0	13.3	4.7	6.0	0.0	8.7
		d	20.0	2.6	87.3	1.3	0.0	5.3	2.7
	剥離・鉄筋露出	e-1	0.0	3.4	11.1	75.6	3.3	1.1	2.2
		e-2	0.0	2.7	0.7	3.3	89.3	0.0	4.0
	剥離・鉄筋露出	c	0.0	3.3	2.0	0.0	3.3	89.3	0.7
		d	1.3	0.7	1.3	2.0	0.7	3.3	88.7
		e	0.0	1.3	0.0	0.7	0.0	4.0	94.0

表-9 各ケースのクラス別再現率

ケース	再現率 (%)							
	ひび割れ	漏水・遊離石灰				剥離・鉄筋露出		
		c	d	e-1 つらら	e-2 錆汁	c	d	e
1	61.1	14.4	22.2	9.3	27.8	21.1	54.5	81.1
2	66.7	10.0	35.6	16.7	56.7	32.2	50.0	63.4
3	91.3	58.0	87.3	75.6	89.3	89.3	88.7	94.0
4	96.7	78.0	86.0	83.3	91.3	97.4	88.7	96.7
5	92.7	64.7	75.3	66.7	86.7	93.4	85.3	94.7

緑色 : True Positiveに該当するゾーン

赤字 : 各クラスの再現率の最高値




図-10 ひび割れのケース別再現率




図-14 漏水・遊離石灰 e-2 錆汁のケース別再現率




図-11 漏水・遊離石灰 c のケース別再現率




図-15 剥離・鉄筋露出 c のケース別再現率




図-12 漏水・遊離石灰 d のケース別再現率




図-16 剥離・鉄筋露出 d のケース別再現率




図-13 漏水・遊離石灰 e-1 つららのケース別再現率




図-17 剥離・鉄筋露出 e のケース別再現率

再現率が若干低下したが、概ね性能の向上が見られ、有効性が確認できた。

また、mixupについては、判断に曖昧性を含むように学習するという特性がある。この特性から、漏水・遊離石灰および剥離・鉄筋露出のように同種のクラス内で損傷程度によりクラスがさらに細分化される条件に対しては、その有効性が期待されたが、従来のデータ拡張ほどの効果は得られなかった。今後、同種の変状のクラス内のみの組み合わせに限定して使用する等、活用方法を工夫した条件での検証を重ねていきたい。

クラスの種類によってばらつきはあるが、全5ケースでは、ケース4のFine-tuning+データ拡張の条件が、大半のクラスおよびデータセット全体で再現率が最高値となった。漏水・遊離石灰cについては、8クラスの中で最も再現率が低く、ケース4でも78%であった。ひび割れからの漏水は、漏水・遊離石灰cという評価とともにひび割れとしても評価を行う変状で、画像としても双方の特徴を有するため、どちらか一方のクラスとしての分類は難しい画像があったためと考えられる。また、漏水・遊離石灰e-2錆汁との誤識別も多く、壁面を液体が上から下に流下するという共通点に起因したものと考えられる。なお、漏水・遊離石灰cは、データ拡張による再現率の向上が最も大きかったクラスであることから、学習データの量を増やすことにより、精度の向上が図れると考えられる。


b) 着目領域の可視化による分類結果の検証

次に、着目領域の可視化を行い、分類結果の検証を行った。深層学習全般における課題の一つに、学習から得

られたモデルにより分類、予測、異常検知等を行なった際、結果の根拠を説明できないというブラックボックス問題が挙げられる。画像認識の分野においては、このような課題に対して、判断根拠を理解するための手法が多数提案されている。それらの提案手法の中で、本研究では、クラスの分類において、着目している領域を可視化するという特徴を有するGrad-CAM (Gradient-weighted Class Activation Mapping)⁴⁹⁾を用いて検証を行なった。Grad-CAMは、CNNでの学習を行った後、クラス分類に至るまでの各特徴マップの寄与の度合いを算出し、その重みを逆伝搬していくという手法により、ヒートマップのような図で、着目領域を図化する技術である。

ケース間の再現率の変化が最も大きかった剥離・鉄筋露出cのクラスについて、テストデータを用いて可視化を行なった結果を図-18に示す。Fine-tuningを行っていないケース1、2とFine-tuningを行なったケース3～5では、明確に傾向が異なっており、再現率の傾向と整合する。ケース3～5では、変状部分に強く反応して、クラスの特徴に寄与していることが明瞭に表れている。また、ケース3、4は剥離・鉄筋露出cと判定した確率がほぼ100%であるのに対してmixupでデータを拡張したケース5では60%で、特徴が明瞭な画像に対しても曖昧さを含んだ判定を行っている。このテストデータに対しては、ケース5の分類性能は劣る結果であった。

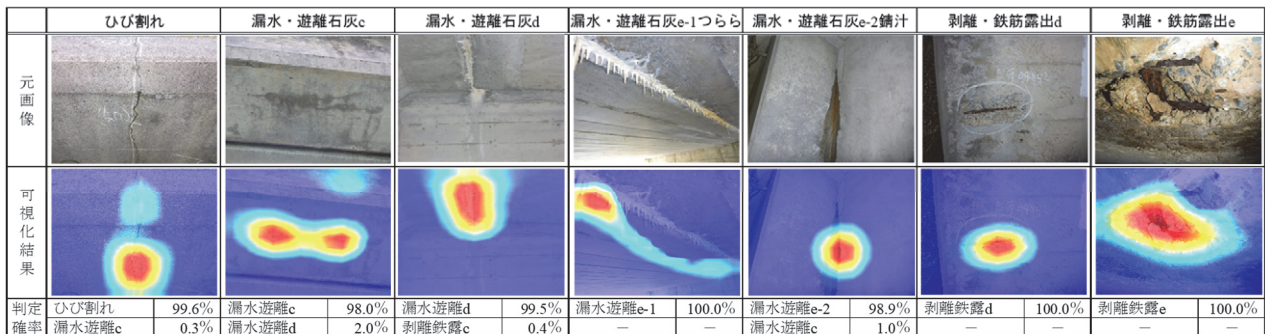
剥離・鉄筋露出c以外のクラスのテストデータについて、ケース4の条件でクラス分類を行った際の可視化結果を図-19に示す。いずれのクラスにおいても変状部分に着目しており、特に剥離・鉄筋露出dについては鉄筋



※1 赤色の領域がクラス分類に最も影響した領域

※2 クラス判定結果は、8クラスのそれぞれの判定確率の中から上位2クラスとその判定確率を記載

図-18 剥離・鉄筋露出cについてのGrad-CAMによる可視化結果



※1 赤色の領域がクラス分類に最も影響した領域

※2 クラス判定結果は、8クラスのそれぞれの判定確率の中から上位2クラスとその判定確率を記載

図-19 ケース4の条件での各クラスのテストデータに対するGrad-CAMによる可視化結果

表-10 深層学習による物体検出の主な手法

	深層学習の内容			物体候補領域の抽出	クラスの分類	領域の特定	備考
	入力	使用するネットワーク	出力				
[1] R-CNN ³⁵⁾	個々の領域画像	CNN	CNN特徴量	Selective Search ³⁶⁾ 等の領域探索手法により、クラスに依存しない候補領域を提案。	CNNにより個々の候補領域内の画像の特徴を抽出し、それを分類器(線形SVM)に入力してクラスを予測。	CNN特徴量から矩形領域のパラメータ(中心位置, 幅, 高さ)へ回帰。	各々の候補領域(約2000個)に対して個別にCNNによる特徴抽出を行うため、速度が遅い。
[2] Fast R-CNN ³⁹⁾	・画像全体 ・候補領域	CNN	CNN特徴量	Selective Search ³⁶⁾ 等の領域探索手法により、クラスに依存しない候補領域を提案。	ROI(Region of Interest; 関心領域)プーリングによって候補領域毎に異なるCNN特徴量を固定長の特徴量に変換した上で、FCN(Fully Convolution Network; 全層畳み込みネットワーク)に入力して学習によりマルチタスク損失を最小化させてクラス分類と矩形領域への回帰を同時に行う。	画像全体に対してCNNによる特徴抽出を行うことで、[1]における解析時間の課題を解消。	画像全体に対してCNNによる特徴抽出を行うことで、[1]における解析時間の課題を解消。
[3] Faster R-CNN ⁴⁰⁾	画像全体	CNN	CNN特徴量	RPN(Region Proposal Network; 領域提案ネットワーク)での学習により、クラスに依存しない候補領域を提案。	ROI(Region of Interest; 関心領域)プーリングによって候補領域毎に異なるCNN特徴量を固定長の特徴量に変換した上で、FCN(Fully Convolution Network; 全層畳み込みネットワーク)に入力して学習によりマルチタスク損失を最小化させてクラス分類と矩形領域への回帰を同時に行う。	候補領域の抽出も深層学習により行うことで、[1]と[2]の課題である「候補領域の冗長的な抽出」「項目毎の不連続性」を解消し、速度と精度の向上を実現。	候補領域の抽出も深層学習により行うことで、[1]と[2]の課題である「候補領域の冗長的な抽出」「項目毎の不連続性」を解消し、速度と精度の向上を実現。
	CNN特徴量	RPN	・候補領域 ・スコア				
	・CNN特徴量 ・候補領域 ・スコア	FCN	・クラス ・矩形領域				
[4] YOLO ⁴¹⁾	画像全体	CNN	・クラス ・矩形領域	---	画像を分割した各グリッドに対して、学習により領域と信頼度(候補領域の精度と物体の有無を反映)、そしてクラスを予測。領域の予測とクラスの予測を結合し、閾値処理等を行ってクラス分類と矩形領域を確定。		[3]に対して速度が大幅に向上したが、精度が若干低下している。
[5] SSD ⁴²⁾	画像全体	FCN	・クラス ・矩形領域	---	学習によりネットワークの中間の各段階で、各々のスケールのCNN特徴マップに対して領域とクラスの予測を行い、各領域で生成する領域内の物体の存在に関するスコアにより物体の形にマッチするように領域形状の調整を行って領域を確定。		[4]より高速で、[3]より高精度な性能を実現。
[6] YOLO v2 ⁴³⁾	画像全体	FCN	・クラス ・矩形領域	---	基本的に[4]を踏襲。 [4]に対して、データセットの矩形を事前にクラスタリングしての学習、マルチスケールトレーニング等により性能を改善。		性能改善により、[3]の精度および[5]の速度を上回る性能を実現。
[7] YOLO v3 ⁴⁴⁾	画像全体	FCN	・クラス ・矩形領域	---	基本的に[6]を踏襲。 [6]に対して、Softmax関数からロジスティック回帰に変更しての分類、3つの異なるスケールでの領域の予測等により性能を改善。		性能改善により、[6]よりも速度が低下したが、精度の向上を実現。

：深層学習を用いている工程

部分、剥離・鉄筋露出eについては鉄筋の腐食が著しい部分に反応していることから、適切に学習が行われた上で分類されていることが裏付けられた。

5. 変状箇所の検出

前章において、変状のクラス分類については、一定の成果が得られた。そこで、本章では、変状領域まで特定する「変状箇所の検出」タスクについて検討を行う。

(1) 物体検出の概要

a) 深層学習による物体検出の手法

深層学習による物体検出は、R-CNNに端を発し、以後多くの手法が提案されている。深層学習による物体検出の主な手法について表-10に示す。

これらの手法のアプローチとしては、大きくは分類問題と回帰問題に分けられる。R-CNN, Fast R-CNN³⁹⁾, Faster R-CNN⁴⁰⁾は分類問題として検出を行う手法である。候補領域を提案した後に、その候補領域が分類器を通過してクラス分類され、候補領域の補正を行って矩形領域(bounding box)が特定される。これに対して、YOLO⁴¹⁾, SSD⁴²⁾, YOLO v2⁴³⁾, YOLO v3⁴⁴⁾は回帰問題として検出を行う手法である。候補領域とクラスを予測した後に、矩形領域を直接生成し、それに対する補正を行って領域の特定を行う。このアプローチの特徴の一つは、候補領域だけでなく、画像全体を利用して周辺の状況も同時に学習するため、背景の誤認識を抑制できる点である。このことにより、変状周辺のコンクリート躯体面の誤認識を

最小限とした、精度の高い検出が期待できる。これら二つのアプローチの中から、分類問題として検出を行う手法の代表として、候補領域に対するクラス分類だけでなく候補領域の探索の段階から深層学習の技術を適用したFaster R-CNNを用いる。また、回帰問題として検出を行う手法については、最新の手法であるYOLO v3を代表とし、これらの二つの手法を用いて、変状検出の検討を行うこととした。

なお、学習に際しては、変状のクラス分類において得られた知見より、データ拡張および学習済みモデルから得られる重みの転用を行った。

b) データセットと出力

深層学習による物体検出におけるデータセットは、クラス分類時のデータセットである画像と正解ラベルに加えて、物体が存在する矩形領域の座標情報が必要となる。変状箇所の検出の検証に際して、変状のクラス分類に用いたデータセットと同じ画像に対して、予め道路橋点検士有資格者により、正解の矩形領域(Ground-truth bounding box)と個々の領域についての変状の正解クラスの設定を行った。変状が細長い領域で斜め方向に分布するような場合には、正解の矩形領域を複数に分割して変状が矩形領域内の大半を占める状況となるように設定を行った。「変状のクラス分類」と「変状箇所の検出」のそれぞれのデータセットの構成例について、図-20に示す。なお、変状箇所の検出時の学習データに対してデータ拡張を行う場合は、画像の変化に伴って矩形領域の座標情報も変化させる必要がある。

また、ここでの入力に対する出力は、クラス分類時は、予測クラスとその判定確率であったが、それらに予測の




図-20 データセットの構成例




図-21 IoU (Intersection over Union) の考え方

矩形領域 (Predicted bounding box) が加わる。

(2) 変状の検出結果

Faster R-CNNとYOLO v3による変状検出結果は、正解クラスと予測クラスとの正誤、予測クラス判定確率および正解の矩形領域と予測の矩形領域の2つの領域の重なり具合により対比を行った。クラスの判定に際しては、CNNによるクラス分類と同様に、8クラスのそれぞれに対する判定確率が算定されるが、その判定確率が最大となるクラスが予測クラスである。2つの領域の重なり具合は、IoU (Intersection over Union) という図-21に示す位置特定の評価指標を算定することにより行った。通常、IoUが0.5以上であれば、良好な予測が行われたと判断することが多い。

図-22にFaster R-CNNとYOLO v3によるコンクリート変状検出結果について示す。

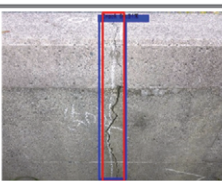

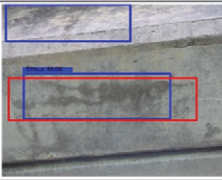
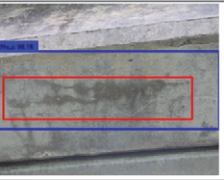
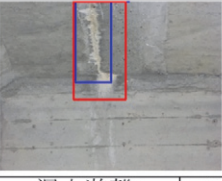
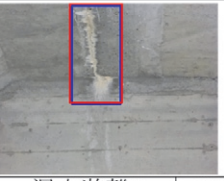
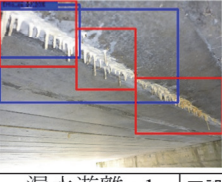
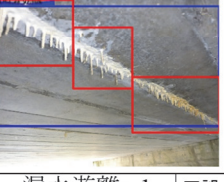
変状の検出を行った結果、いずれのテストデータにおいても、Faster R-CNNとYOLO v3の双方の手法で、予測クラスは正解クラスと一致した。今回用いたテストデータに対しては、検出漏れ (False Negative) は生じなかったが、漏水・遊離石灰cの画像に対するFaster R-CNNによる


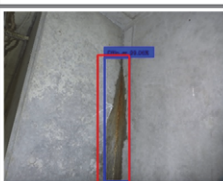





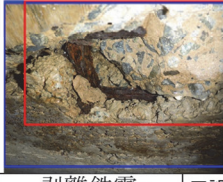
検出において、主桁側面の汚れと考えられる部分を漏水・遊離石灰dとする誤検出 (False Positive) があった。正解クラスと予測クラスとの正誤、予測クラス判定確率については、手法間で大きな差は生じなかったが、8種類の変状のうち3種の変状でYOLO v3の予測クラス判定確率の方が5%以上高い数値となり、YOLO v3の方が若干優位な結果であった。

IoUについては、漏水・遊離石灰cのみFaster R-CNNの方が高い値で、漏水・遊離石灰e-1と剥離・鉄筋露出dは同等の値となったが、それら以外の5種の変状については、YOLO v3がFaster R-CNNを大きく上回った。IoUに差が生じた5種の変状の検出結果のうち剥離・鉄筋露出cを除く4種の変状では、Faster R-CNNによる予測の矩形領域は、正解の矩形領域に対して狭小な範囲となっている。ひびわれについては、ひび割れ幅の細くなる画像の上方部分、漏水・遊離石灰e-2については漏水部分が細くなっている変状の上方部分が検出できていないことにより、IoUの値に差が生じている。漏水・遊離石灰e-1については、細長い領域で斜め方向に分布している変状に対して、変状が矩形領域内の大半を占めるように正解の矩形領域を複数に分割して設定していた。そのため、双方の手法ともに広域的に検出を行ってIoUの評価としては低調であったが、Faster R-CNNはつらら状の遊離石灰のサイズが小さくなる画像の右下部分を、同様に検出できていない。YOLO v3の主要な改善点の一つとして、3つの異なるスケールで検出を行う点が挙げられる。このことにより、より小さな物体の検出の精度の向上が図られていることから、YOLO v3の矩形領域の特定の精度が優位になったと考えられる。

また、人や顔および車等の一般的によく行われる物体検出では、背景と検出対象が明らかに異なるが、コンクリート変状の検出を行う場合は、背景であるコンクリート躯体面と検出対象である変状に外観上の極端な違いはない。そのため、分類と回帰とで、背景の誤認識に関して優劣が生じるのではないかと考えていたが、双方の手法ともにコンクリート躯体面に対する誤認識はなかった。

変状のクラス分類では、アップで撮影した単一のクラスの変状のみが存在する画像を対象に、該当するクラスの分類を行った。本研究では、変状のクラス分類と同様の画像に対して変状箇所の検出を行ったが、実際の点検業務への適用に際しては、広域的な画像内に混在する複数の変状について、それぞれの領域と該当するクラスを適切に予測できなければならない。この点からも、多数の物体の検出に対応が可能で、3つの異なるスケールで検出を行うことができるYOLO v3は、変状の検出に対する適性が高いと考えられる。しかしながら、このタスクは難易度が高いため、多様なデータに対して検出をロバストにするためには、さらなる検証が必要である。

		Faster R-CNN		YOLO v3	
ひび割れ	出力画像				
	予測クラス	ひび割れ	正誤	ひび割れ	正誤
	IoU	判定確率 90.5%	○	判定確率 98.5%	○
漏水・遊離石灰 c	出力画像				
	予測クラス	漏水遊離c	正誤	漏水遊離c	正誤
	IoU	判定確率 96.0%	○	判定確率 98.1%	○
漏水・遊離石灰 d	出力画像				
	予測クラス	漏水遊離d	正誤	漏水遊離d	正誤
	IoU	判定確率 90.4%	○	判定確率 97.0%	○
漏水・遊離石灰 e-1	出力画像				
	予測クラス	漏水遊離e-1	正誤	漏水遊離e-1	正誤
	IoU	判定確率 97.2%	○	判定確率 97.1%	○

		Faster R-CNN		YOLO v3	
漏水・遊離石灰 e-2	出力画像				
	予測クラス	漏水遊離e-2	正誤	漏水遊離e-2	正誤
	IoU	判定確率 94.1%	○	判定確率 99.1%	○
剥離・鉄筋露出 c	出力画像				
	予測クラス	剥離鉄露c	正誤	剥離鉄露c	正誤
	IoU	判定確率 99.4%	○	判定確率 99.5%	○
剥離・鉄筋露出 d	出力画像				
	予測クラス	剥離鉄露d	正誤	剥離鉄露d	正誤
	IoU	判定確率 100.0%	○	判定確率 99.5%	○
剥離・鉄筋露出 e	出力画像				
	予測クラス	剥離鉄露e	正誤	剥離鉄露e	正誤
	IoU	判定確率 100.0%	○	判定確率 99.8%	○

□ : Ground-truth bounding box (正解の矩形領域), □ : Predict bounding box (予測の矩形領域)

図-22 FasterR-CNNとYOLOv3によるコンクリート変状検出結果

6. おわりに

本研究は、構造物点検の省力化を可能とする技術として有望な、深層学習を活用した画像認識による変状の自動検出の有効性と、精度向上を図る方策について検討を行ったものである。本研究で得られた主たる知見は以下のとおりである。

- (1) 深層学習を用いた画像のクラス分類により、橋梁点検時の撮影画像に対するコンクリート変状の分類が、損傷程度の分類まで含めて高い精度で可能であることが確認できた。
- (2) コンクリート変状のクラス分類については、変状に関する学習データが十分でない場合でも、一般的な画像についての事前学習済みモデルを用いた転移学習 (Fine-tuning) により、分類精度の格段の向上が図れることがわかった。

- (3) 深層学習の課題の一つにブラックボックス問題が挙げられるが、テストデータに対してGrad-CAMにより着目領域の可視化を行なった結果、適切な部分に着目した上で判断を行っていることが把握できた。
- (4) コンクリートの変状箇所の検出では、クラスと変状領域の双方について妥当な予測結果が得られた。Faster R-CNNとYOLO v3の2手法の比較では、YOLO v3の方が領域の特定に関する精度において優位な結果となり、最新の手法であるYOLO v3のコンクリート変状検出についての適性が確認できた。

また、深層学習によるクラス分類は、経験が浅い技術者が現地での撮影画像を基に損傷程度の判断を行う際の、支援ツールとしても活用できると考えられる。

最後に、今後の課題について述べる。本研究は、データが限られた条件での検討であったため、今後は学習データの充実および多様なテストデータに対する評価・検

証を行うとともに、画像の解析的処理の工夫等を図って、分類および検出の精度を高めていく必要がある。また、橋梁点検の実務への活用を見据えると、範囲の検出のみでは不十分で、寸法等の定量的情報の把握が必要であるため、現在その検討を行っている。さらに、今回は、橋梁定期点検要領における全26損傷のうちの3種類のコンクリート変状を対象とした検討であったが、今後、鋼部材も含む他の変状についての展開、変状原因の識別への適用等について検討を行う予定である。

謝辞：本研究を遂行するにあたり、山口大学工学部知能情報工学科卒業生（現山口県庁）の堀見輔氏には深層学習のプログラミングに関して多大なる協力をいただきました。ここに記して感謝の意を表します。また、本研究はJSPS科研費 15K06165（研究代表者：中村秀明）の助成を受けたものです。ここに記して感謝の意を表します。

参考文献

- 1) 道路法施行規則 省令 第四条の五の五（道路の維持又は修繕に関する技術的基準等），平成 26 年 3 月 31 日公布
- 2) 小出博：特殊用途カメラの研究「画像診断支援システム」開発とその活用，映像情報，pp. 37-40, 1990.10.
- 3) 山口友之，橋本周司：Gray-scale Hough 変換を用いたコンクリート表面のひび割れ検出，情報処理学会研究報告，pp. 57-64, 2004.
- 4) 山口友之，橋本周司：既設コンクリート構造物におけるひび割れ幅の実画像計測，電気学会論文誌 C, Vol. 127, No. 4, pp. 605-614, 2007.
- 5) 藤田悠介，中村秀明，浜本義彦：画像処理によるコンクリート構造物の高精度なひび割れ自動抽出，土木学会論文集 F, Vol. 66, No. 3, pp. 459-470, 2010.
- 6) 木元亮輔，藤田悠介，河村圭，浜本義彦：画像処理によるコンクリート構造物のひび割れ計測の実用化に関する基礎研究，ファジィシステムシンポジウム講演論文集，Vol. 26, pp. 874-879, 2010.
- 7) 藤田悠介，中村秀明，浜本義彦：画像処理によるコンクリート構造物のひび割れ幅の分類，コンクリート工学年次論文集，Vol. 34, No. 1, pp. 1792-1797, 2012.
- 8) 全邦釘，片岡望，三輪知寛：統計的特徴および幾何学的特徴に着目したコンクリート表面ひび割れの画像解析による検出，土木学会論文集 F3, Vol. 70, No. 2, pp. I_1-I_8, 2014.
- 9) 全邦釘，井後敦史，橋本和明：画像解析によるひび割れ検出とハフ変換による型枠跡および P コン跡の同定，コンクリート工学年次論文集，Vol. 37, No. 1, pp. 1777-1782, 2015.
- 10) 武田均，堀口賢一，小山哲，丸屋剛：ウェーブレット変換を用いたコンクリートのひび割れ画像解析手法の開発，コンクリート工学年次論文集，Vol. 28, No. 1, pp. 1895-1900, 2006.
- 11) 丸屋剛，堀口賢一，小山哲，澤健男：ウェーブレット変換を用いた床版コンクリートのひび割れ調査の実用化，コンクリート工学年次論文集，Vol. 29, No. 2, pp. 691-696, 2007.
- 12) 小山哲，丸屋剛，堀口賢一，澤健男：ガボールウェーブレット変換を用いたコンクリートのひび割れ画像解析技術の開発，土木学会論文集 E2, Vol. 68, No. 3, pp. 178-194, 2012.
- 13) 西川貴文，吉田純司，杉山俊幸，斉藤成彦，藤野陽三：木構造状フィルタを用いたコンクリートのクラック抽出のためのロバストな画像処理システム，土木学会論文集 A, Vol. 63, No. 4, pp. 599-616, 2007.
- 14) 河村圭，宮本文穂，中村秀明，佐藤亮：対話型遺伝的アルゴリズムによるデジタル画像からのひび割れ抽出，土木学会論文集，No. 742/VI-60, pp. 115-131, 2003.
- 15) 河村圭，吉野孝亮，Amir Tarighat，中村秀明：遺伝的アルゴリズムおよび決定木を用いたひび割れ抽出のための画像処理パラメータ有効範囲の特定，土木学会論文集 F3, Vol. 69, No. 2, pp. I_13-I_23, 2013.
- 16) 河村圭，村上慧季，塩崎正人：対話型遺伝的アルゴリズムを用いたひび割れ半自動抽出手法の研究，土木学会論文集 F3, Vol. 71, No. 2, pp. I_114-I_122, 2015.
- 17) 野村泰稔，村尾彩希，阪口幸広，古田均：深層畳み込みニューラルネットワークに基づくコンクリート表面のひび割れ検出システム，土木学会論文集 F6, Vol. 73, No. 2, pp. I_189-I_198, 2017.
- 18) 全邦釘，井後敦史：Random Forest によるコンクリート表面ひび割れの検出，土木学会論文集 F3, Vol. 71, No. 2, pp. I_1-I_8, 2015.
- 19) 全邦釘，嶋本ゆり，大窪和明，三輪知寛，大賀水田生：ディープラーニングおよび Random Forest によるコンクリートのひび割れ自動検出手法，土木学会論文集 F3, Vol. 73, No. 2, pp. I_297-I_307, 2017.
- 20) 中村優志，児玉聖治，河村圭，村上慧季，塩崎正人：深層学習を用いたひび割れ領域の自動識別法に関する研究，土木学会第 72 回年次学術講演会，pp. 45-46, 2017.
- 21) 塩崎正人，菊地典明，前川了重，益山茂樹，石坂哲宏，佐田達典：画像計測による照明の陰影を利用した変状抽出手法の研究，土木学会論文集 F3, Vol. 67, No. 2, pp. I_119-I_124, 2011.
- 22) 石森章之，佐田達典，石坂哲宏，塩崎正人：RGB 単色光と陰影を利用したトンネルコンクリート壁面のひび割れ検知に関する研究，土木学会論文集 F3, Vol. 69, No. 2, pp. I_82-I_89, 2013.
- 23) 塩崎正人，石森章之，菊地典明，佐田達典：画像計測による照明の陰影を利用した変状抽出手法の研究，コンクリート工学年次論文集，Vol. 36, No. 1, pp. 2152-2157, 2014.
- 24) 石森章之，佐田達典，塩崎正人：投光器の照射角度と陰影の幅を利用したコンクリート壁面の段差高計測に関する研究，土木学会論文集 F3, Vol. 70, No. 2, pp. I_249-I_256, 2014.
- 25) 鵜飼正人：画像処理によるトンネル構造物ひび割れ検査精度の向上，鉄道総研報告，Vol. 24, No. 3, pp. 53-56, 2010.
- 26) 鵜飼正人，長峯望，御崎哲一，坂本保彦：トンネル変状抽出のための高精度画像処理手法の開発，サイバネティクス，Vol. 17, No. 2, pp. 58-62, 2012.
- 27) 鵜飼正人：画像処理技術を用いてトンネルを検査する，RRR, Vol. 72, No. 9, pp. 20-23, 2015.
- 28) 横山傑，松本高志：ディープラーニングを用いたコ

- ンクリートのひび割れ自動検出器の開発, 応用力学シンポジウム講演論文集, Vol. 19, pp. 125-126, 2016.
- 29) 横山傑, 松本高志: Deep Learning によるコンクリートの変状自動検出器の開発と Web システムの実装, 応用力学シンポジウム講演論文集, Vol. 20, pp. 31-32, 2017.
- 30) 横山傑, 松本高志: SNS を用いた Deep Learning によるコンクリートの変状自動検出器の開発, 土木情報学シンポジウム講演集, Vol. 42, pp. 235-236, 2017.
- 31) 鵜飼正人, 長峯望: 画像処理技術による構造物検出手法の高精度化, 鉄道総研報告, Vol. 28, No. 11, pp. 11-16, 2014.
- 32) 国土交通省 道路局 国道・防災課: 橋梁定期点検要領, 2014.
- 33) 山下隆義: イラストで学ぶディープラーニング, 講談社, 2016.
- 34) 新田恭士: 国交省におけるインフラロボット導入の取組と AI への期待, 「AI 時代のインフラメンテナンスとビッグデータのあり方」セミナー, 2017.10.16.
- 35) Girshick, R., Donahue, J., Darrell, T. and Malik, J.: Rich feature hierarchies for accurate object detection and semantic segmentation, *Proc. IEEE CVPR*, pp. 580-587, 2014.
- 36) Uijlings, J. R., van de Sande, K. E., Gevers, T. and Smeulders, A. W.: Selective search for object recognition, *International Journal of Computer Vision (IJCV)*, Vol. 104, No. 2, pp. 154-171, 2013.
- 37) LeCun, Y., Boser, B., Denker, J., Henderson, D., Howard, R., Hubbard, W. and Jackel, L.: Backpropagation applied to handwritten zip code recognition, *Neural Computation*, Vol. 1, No. 4, pp. 541-551, 1989.
- 38) He, K., Zhang, X., Ren, S. and Sun, J.: Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition, *European Conference on Computer Vision (ECCV)*, 2014.
- 39) Girshick, R.: Fast R-CNN, *IEEE International Conference on Computer Vision (ICCV)*, 2015.
- 40) Ren, S., He, K., Girshick, R. and Sun, J.: Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks, *Neural Information Processing Systems* 28, 2015.
- 41) Redmon, J., Divvala, S., Girshick, R. and Farhadi, A.: You only look once: Unified, real-time object detection, *Computer Vision and Pattern Recognition (CVPR)*, 2015.
- 42) Liu, W., Anguelov, D., Erhan, D., Szegedy, C., Reed, S., Fu, C. and Berg, A.: SSD: Single Shot MultiBox Detector, *European Conference on Computer Vision (ECCV)*, pp. 1-15, 2016.
- 43) Redmon, J. and Farhadi, A.: YOLO9000: Better, Faster, Stronger, *Computer Vision and Pattern Recognition (CVPR)*, pp. 7263-7271, 2017.
- 44) Redmon, J. and Farhadi, A.: YOLOv3: An Incremental Improvement, *arXiv: 1804.02767*, 2018.
- 45) Krizhevsky, A., Sutskever, I. and Hinton, G. E.: ImageNet classification with deep convolutional neural networks, *Neural Information Processing Systems*, pp. 1097-1105, 2012.
- 46) LeCun, Y., Bottou, L., Bengio, Y. and Haffner, P.: Gradient-Based Learning Applied to Document Recognition, *Proc. IEEE CVPR*, pp. 1-46, 1998.
- 47) Zhang, H., Cisse, M., Dauphin, Y. N. and Lopez-Paz, D.: mixup: Beyond Empirical Risk Minimization, *arXiv: 1710.09412*, 2017.
- 48) 中山英樹: 深層畳み込みニューラルネットワークによる画像特徴抽出と転移学習, 電子情報通信学会技術研究報告, Vol. 115, No. 146, pp. 55-59, 2015.
- 49) Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D. and Batra, D.: Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization, *IEEE International Conference on Computer Vision (ICCV)*, pp. 618-626, 2017.

(2018. 6. 20 受付)

STUDY ON VARIANT EXTRACTION OF CONCRETE STRUCTURES USING IMAGE RECOGNITION BY DEEP LEARNING

Kosuke AOSHIMA, Shinya KAWAMURA, Satoshi NAKANO
and Hideaki NAKAMURA

In maintaining and managing social infrastructure, saving labor and improving efficiency in visual inspections is one of the urgent issues in the recent years. In this research, in order to solve this problem, we apply image recognition using deep learning to images acquired by digital cameras and conducted evaluations on a method that automatically assesses classifications related to ranking by detecting deformations. Additionally, through verification using images from actual structures, it was verified that image recognition using deep learning is an effective method of saving labor and improving efficiency in visual inspections.